


1. ESTUDIOS ESTADÍSTICOS.



Un estudio estadístico queda determinado por sus cuatro fases de actuación:

- 1- **Recopilar** datos.
- 2- **Ordenar** los datos recogidos.
- 3- **Analizar** los datos.
- 4- **Interpretar** los resultados.

Así, la **ESTADÍSTICA** se define como la ciencia encargada de recopilar y ordenar datos relativos a diversos fenómenos para su posterior análisis e interpretación.

1.1. DEFINICIONES:

- La **población** es el conjunto formado por todos los elementos de un estudio estadístico.
- Una **muestra** es una parte de la población que se selecciona para realizar el estudio.
- Un **individuo** es cada uno de los elementos de la población o la muestra.
- El **tamaño de la muestra** es el número de individuos que la componen y lo representamos por **N**.

Una **variable estadística** es una característica observable que permite clasificar a los individuos de una muestra o una población.

Una **variable estadística unidimensional** resulta al estudiar una característica de los individuos de una población. La variable unidimensional X queda determinada por los datos $x_1, x_2, \dots, x_n$.

1.2. TIPOS DE VARIABLES:

Según los valores que puedan tomar, las variables se clasifican en:

Cualitativas		Los datos de la variable son cualidades, no números.	Deporte practicado, color de pelo...
Cuantitativas	Discretas	Los datos de la variable son números. La variable toma valores aislados.	Número de hermanos, canastas logradas por un jugador en un partido...
	Continuas	Los datos de la variable son números. La variable puede tomar cualquier valor intermedio entre dos números dados.	Tiempo dedicado al estudio diario, estatura de los alumnos de un colegio...

Presta atención

La muestra debe ser **representativa** de la población con objeto de poder extraer conclusiones válidas para el total de la misma.

Lenguaje matemático

Los valores que toma una variable estadística cualitativa se denominan **modalidades**.

Lenguaje matemático

- **Muestreo aleatorio simple**
Cuando los individuos de la muestra se eligen al azar.
- **Muestreo aleatorio estratificado**
Cuando la población está dividida en grupos, también llamados estratos, por ejemplo varones y mujeres, y la elección se realiza de forma directamente proporcional al número de individuos de cada grupo.

1.3. RECUENTO DE DATOS Y PRESENTACIÓN DE DATOS:

¿Cómo nos podemos encontrar los datos?

1. Suelos sin agrupar.

Si los datos están sueltos, sin agrupar, somos nosotros los que los ordenamos de menor a mayor y a partir de ahí, se calcula la tabla de frecuencia.

2. Agrupados en clases o intervalos.

Si los datos están agrupados en clase o intervalos, lo que hacemos es calcular su valor medio, entre los dos extremos del intervalo y ya tenemos calculado la marca de clase y a partir de ahí, se calcula la tabla de frecuencia igual que antes.

3. Gráficos estadísticos.

Presta atención

- Si la variable estadística es cuantitativa, se ordenan los datos en orden ascendente y se anota el número de veces que aparece cada uno.
- Si la variable estadística es cualitativa, se escribe cada dato y se anota el número de veces que aparece cada uno de ellos.

En un estudio estadístico, los datos se recogen, se cuentan y se agrupa

POR EJEMPLO: RECuento DE DATOS.

Ramón ha escrito en su cuaderno el número de personas que habitan en cada una de las viviendas de su edificio: 2, 2, 4, 1, 1, 3, 3, 5, 2, 4, 2, 5, 6, 1, 3, 2

Después, los ordena y anota el número de veces que se repite cada dato.

1	1	1		
2	2	2	2	2
3	3	3		
4	4			
5	5			
6				

Personas	Recuento
1	3
2	5
3	3
4	2
5	2
6	1

Presta atención

Cuando la variable estadística es cuantitativa, podemos agrupar los datos en intervalos llamados **clases**.

- Cada **clase** es un intervalo, cerrado por la izquierda y abierto por la derecha, en el que se agrupan los datos.
- La **marca de clase** es el punto medio del intervalo y se toma como dato que lo representa.
- La **amplitud** de un intervalo es su tamaño, es decir, la diferencia entre sus extremos

Pero también podemos agrupar los datos en **intervalos o clases**, se realiza cuando el número de datos distintos es casi tan grande como el número total de datos, para poder estudiarlas es conveniente agruparlas los datos así.

POR EJEMPLO: DATOS AGRUPADOS EN INTERVALOS.

[150, 156) [156, 162) [162, 168) [168, 174) [174, 180)

Calculamos las **marcas de clase** sumando los extremos de cada intervalo y dividiendo por 2:

$$\frac{150 + 156}{2} = 153$$

Por último, realizamos el recuento.

Estatura	Marca de clase	Recuento
[150, 156)	153	4
[156, 162)	159	6
[162, 168)	165	7
[168, 174)	171	8
[174, 180)	177	7

1.4. TABLA DE FRECUENCIAS:

Los **datos**, x_i , son cada uno de los posibles resultados de la variable estadística estudiada.

Para organizar y extraer la información de los datos recogidos en el recuento podemos construir una tabla de frecuencias.

Para un dato estadístico:

- la **frecuencia absoluta**, f_i , es la cantidad de veces que se repite.
- la **frecuencia relativa**, h_i , es el cociente entre su frecuencia absoluta y el número total de datos: $h_i = \frac{f_i}{N}$
- la **frecuencia absoluta acumulada**, F_i , es la suma de las frecuencias absolutas de los datos menores o iguales que él: $F_i = f_1 + f_2 + \dots + f_i$
- la **frecuencia relativa acumulada**, H_i , es la suma de las frecuencias relativas de los datos menores o iguales que él: $H_i = h_1 + h_2 + \dots + h_i$

Presta atención

- El **porcentaje** equivalente a cada frecuencia relativa se calcula multiplicando cada frecuencia por 100:
$$h_i \cdot 100$$
- $f_1 + f_2 + \dots + f_n = N$
- $h_1 + h_2 + \dots + h_n = 1$

Podemos organizar los datos en una tabla (primera columna) que incluya todas las frecuencias citadas anteriormente y así tenemos una tabla de frecuencia. Cuando el número de estudio es grande, organizamos dichos datos en intervalos que denominamos clases.

2. GRÁFICOS ESTADÍSTICOS.

La representación gráfica de los datos estadísticos nos permitirá tener una idea clara de su distribución y según el tipo de variable estadística conviene usar un tipo de gráfico u otro.

Para organizar e interpretar los datos obtenidos en un estudio estadístico utilizaremos, principalmente, estos gráficos estadísticos:

UD 1: ESTADÍSTICA

2.1. DIAGRAMA DE BARRAS.

Este gráfico es útil para representar cualquier tipo de variable estadística, aunque se considere idóneo para las variables cuantitativas discretas y las cualitativas.

Para elaborar un **diagrama de barra**, se representan:

- Los datos de la variable estadística en el eje horizontal.
- Las frecuencias en el eje vertical.

Sobre cada dato se dibuja una barra cuya longitud corresponda su frecuencia



2.2. HISTOGRAMA.



Para elaborar un histograma se representa:

- Los datos de la variable estadística, agrupados en clases, en el eje horizontal.
- Las frecuencias en el eje vertical.

Si los intervalos tienen la misma amplitud Sobre cada uno se dibuja un rectángulo cuya altura sea proporcional a su frecuencia.

2.3. DIAGRAMA DE SECTORES.

Con este tipo de gráfico puede representarse cualquier variable estadística, siendo muy adecuado para variables cualitativas.


En un **diagrama de sectores** se representan los datos de la variable estadística en un círculo dividido en sectores cuya amplitud es proporcional a la frecuencia de cada dato.

$$\text{Ángulo del sector circular} = h_i \cdot 360^\circ$$






2.4. POLÍGONO DE FRECUENCIAS.

Un **polígono de frecuencia** es un gráfico que se representa uniendo los puntos (x,y) determinados por los datos de la variable estadística como coordenadas x, y sus frecuencias, como coordenada y.



RESUMEN:

Diagrama de barras	Histograma	Diagrama de sectores
 En el eje de abscisas se escriben los datos de la variable y en el eje de ordenadas las frecuencias. Sobre cada valor se levanta una barra cuya altura es igual a la frecuencia.	 Se divide el eje de abscisas en intervalos y se levanta un rectángulo en cada tramo, cuya altura es igual a la frecuencia asignada al intervalo.	 El círculo se divide en tantos sectores como datos tenga la variable, siendo su amplitud proporcional a la frecuencia del dato.


Como se puede observar:

- ✓ en el diagrama de barras, se han unido los extremos superiores de las barras.
- ✓ En el histograma, los puntos medios de los lados superiores de los rectángulos.

Al hacer esto, aparece un nuevo gráfico que se denomina **POLÍGONO DE FRECUENCIAS**.

Polígonos de frecuencias


Si en un histograma se unen con segmentos los puntos medios de las bases superiores de los rectángulos se obtiene el **polígono de frecuencias**.




Se cumple que el área del recinto limitado por el eje de abscisas y el polígono de frecuencias es igual a la suma de las áreas de los rectángulos.

2.5. OTROS.




OTROS GRÁFICOS ESTADÍSTICOS:



Son dibujos alusivos al carácter estadístico estudiado y donde el tamaño a de los mismos es proporcional a la frecuencias absolutas correspondientes



Mapa de una provincia, región o territorio nacional coloreado en diferentes tonos y colores con unos cuadros al margen que indican su significado.



****Si utilizamos las frecuencias acumuladas; obtenemos el histograma de frecuencias acumuladas y su polígono de frecuencias se consigue uniendo los vértices superiores derechos de cada rectángulo.**

El gráfico más adecuado para representar los datos obtenidos dependerá del tipo de variable que se estudia:

- **Cualitativa**→ Diagrama de barras o diagrama de sectores.
- **Cuantitativa discreta**→ Diagrama de barras, polígono de frecuencias o diagrama de sectores.
- **Cuantitativa continua** ->Histograma o polígono de frecuencia.

En algunas ocasiones queremos representar datos correspondientes a diferentes periodos de tiempo, o a distintas cualidades. Así, cuando es necesario comparar situaciones podemos construir **diagramas de barras adosadas**. En este tipo de gráficos representamos los datos de diferentes variables para poder analizarlos de forma conjunta.

UD 1: ESTADÍSTICA

También podemos realizar un histograma y un polígono de frecuencias utilizando las frecuencias acumuladas. En este caso, el polígono de frecuencias es la línea poligonal que une los vértices superiores de la derecha de cada rectángulo.


EJEMPLO:

Las notas de una clase en la asignatura de Educación Física han sido:

5,9; 1,7; 5,8; 4; 9,8; 6,7; 5,4; 3; 7,3; 7; 8; 5; 7,9; 6;
4,8; 1,3; 9,2; 4

Agrupar los datos en 5 clases de igual amplitud, indica las frecuencias absolutas y haz un gráfico donde esté representado el histograma y el polígono de frecuencias.

Solución



3. MEDIDAS DE CENTRALIZACIÓN Y DE POSICIÓN:

Para estudiar una distribución de frecuencias conviene dar algunas medidas objetivas que describan el comportamiento de los datos. Se agrupan en las siguientes categorías:

A. MEDIDAS DE CENTRALIZACIÓN. Aquellos valores que representan a la distribución en su conjunto.

3.1. Media Aritmética.

La **media aritmética** es el resultado de dividir la suma de cada dato multiplicado por su frecuencia entre el número total de datos. Si los datos están agrupados en clases, se toma como x_i la marca de clase.

$$\bar{x} = \frac{x_1 \cdot f_1 + x_2 \cdot f_2 + \dots + x_n \cdot f_n}{N}$$

Para expresar de un modo abreviado la fórmula del cálculo de la media escribimos:

$$\bar{x} = \frac{\sum_{i=1}^n x_i \cdot f_i}{N}$$

3.2. Moda. Intervalo Modal

La **moda, Mo**, es el dato que tiene mayor frecuencia.

La moda puede no ser única: si hay dos datos que tienen la mayor frecuencia, la variable estadística es **bimodal**; si son tres, **trimodal**, etc.

Para datos agrupados en intervalos, la Moda se calcula de la siguiente forma:

- Se busca el intervalo modal, es decir, aquel donde la frecuencia absoluta es mayor. Llamaremos $[L_i, L_{i+1})$ a este intervalo.
- Si no necesitamos mucha precisión en el cálculo de la Moda, podemos tomar como valor aproximado de la misma, la marca de clase del intervalo modal.

Si los datos están agrupados en clase el intervalo que contiene a la moda se llama **intervalo modal**. En este caso como aproximación de estas medidas de centralización se puede tomar la casa de clase de dicho intervalo.

3.3. Mediana. Intervalos mediano o medianal.

La **mediana, Me**, es el valor que ocupa la posición central, una vez ordenados los datos. Hay tantos valores menores como mayores que él. Si el número de datos es impar, la mediana es el dato central, y si es par, la mediana se halla calculando la media de los dos datos centrales.

Para datos agrupados en intervalos, la mediana se calcula de la siguiente forma:

- Se busca el intervalo en el que se encuentra la mediana (El valor que divide a la difícil distribución en dos partes iguales) Este intervalo se denota $[L_i, L_{i+1})$ y se llama intervalo medianal
- Si no necesitamos mucha precisión podemos tomar como valor aproximado de la mediana la marca de clase correspondiente al intervalo medianal

Si los datos están agrupados en clase el intervalo que contiene a la mediana se llama **intervalo mediano**. En este caso como aproximación de estas medidas de centralización se puede tomar la casa de clase de dicho intervalo.

Se ha realizado un estudio estadístico en un curso de surf con jóvenes de edades comprendidas entre 14 y 22 años.

Edad	x_i	f_i	F_i	h_i	H_i
[14, 16)	15	6	6	0,3	0,3
[16, 18)	17	2	8	0,1	0,4
[18, 20)	19	3	11	0,15	0,55
[20, 22)	21	9	20	0,45	1
	N	20		1	

A partir de la tabla de frecuencias podemos calcular las **medidas de centralización**.

• Media aritmética: $\bar{x} = \frac{15 \cdot 6 + 17 \cdot 2 + 19 \cdot 3 + 21 \cdot 9}{20} = 18,5 \text{ años}$

• Intervalo modal: es el intervalo [20, 22), porque es el que tiene mayor frecuencia absoluta.

• Intervalo mediano: es el intervalo [18, 20), ya que su frecuencia relativa acumulada es la primera que supera 0,5.

B. MEDIDAS DE POSICIÓN.

Estas medidas dan los valores de algunas posiciones de interés en el conjunto de los datos.

- 3.4. **Cuartiles.** Si en lugar de partir la totalidad de los individuos en dos mitades (Mediana), lo hacemos en cuatro partes iguales, obtenemos los cuartiles.
- Q_1 = primer cuartil o cuartil inferior:** es el valor de la variable que deja el 25% de la población de debajo de él.
- Q_2 = segundo cuartil o Mediana:** es el valor de la variable que deja el 50% de la población de debajo de él.
- Q_3 = Tercer cuartil o cuartil superior:** es el valor de la variable que deja el 75% de la población de debajo de él.
- 3.5. **Deciles.** Son los valores de la distribución que dividen la totalidad de los individuos en 10 partes iguales serían: $D_1, D_2, D_3, \dots, D_{10}$, donde D_K deja por debajo el $(K-1) \cdot 10\%$, es decir:
- D_1 deja por debajo el 10% de los individuos.
 - D_2 deja por debajo el 20% de los individuos.
 - D_3 deja por debajo el 30% de los individuos.
 -
 - D_9 deja por debajo el 90% de los individuos.

En el caso continuo se hace de manera idéntica como se hizo en los cuartiles

- 3.6. **Percentiles.** Son los valores de la distribución que dividen la totalidad de los individuos en 100 partes iguales.
- En el caso continuo se hace de manera idéntica como se hizo en los cuartiles y percentiles.

Seguramente te habrás dado cuenta de que:

$$P_{25} = Q_1$$

$$P_{50} = D_5 = Q_2 = M_e$$

$$P_{75} = Q_3$$


También podemos calcular las **medidas de posición**.

- El intervalo $[14, 16)$ es el primero cuya frecuencia relativa acumulada supera 0,25. Decimos que su marca de clase es el **primer cuartil**: $Q_1 = 15$
- El intervalo $[18, 20)$ es el primero en el que H_i supera 0,5. Decimos que su marca de clase es el **segundo cuartil**: $Q_2 = M_e = 19$
- El intervalo $[20, 22)$ es el primero en el que H_i supera 0,75. Decimos que su marca de clase es el **tercer cuartil**: $Q_3 = 21$

3.7. Diagrama y caja de bigotes.

Para describir la dispersión y simetría de los datos, podemos construir un **diagrama de caja y bigotes**.

Si representamos los datos del estudio sobre las edades de los jóvenes del curso de surf, se observa que la variable no es simétrica dado que la mediana no está centrada en la caja.



La parte derecha de la caja es menor que la izquierda, es decir, los datos entre el 50 % y el 100 % están más concentrados que los comprendidos entre el 0 % y el 50 %.

4. MEDIDAS DE DISPERSIÓN:

Estas medidas, nos indican si los datos están muy agrupados en torno a un valor central o sí, por el contrario, están muy dispersos respecto a ese valor. Generalmente si estas medidas están próximas a cero .es porque los datos están agrupados, y si, por el contrario, están lejos de cero, están dispersos. (aunque estar cerca y lejos de cero siempre es muy relativo).

4.1. Rango o recorrido.

- El **rango o recorrido, R**, es la diferencia entre el dato mayor y el menor.

4.2. Desviación media.

- La **desviación media** es la media aritmética de los valores absolutos de las diferencias entre la media y los diferentes datos.

$$DM = \frac{|x_1 - \bar{x}| \cdot f_1 + |x_2 - \bar{x}| \cdot f_2 + \dots + |x_n - \bar{x}| \cdot f_n}{N}$$

4.3. Varianza

- La **varianza** es la media aritmética de los cuadrados de las diferencias entre cada dato y la media.

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot f_i}{N} = \frac{x_1^2 \cdot f_1 + x_2^2 \cdot f_2 + \dots + x_n^2 \cdot f_n}{N} - \bar{x}^2 = \frac{\sum_{i=1}^n x_i^2 \cdot f_i}{N} - \bar{x}^2$$

(varianza= media de los cuadrados-cuadrado de la media)

4.4. Desviación típica

La **desviación típica** Es la raíz cuadrada positiva de la varianza. Se denota por σ . Es el parámetro de dispersión más utilizado, y además viene dado en las mismas unidades que los datos, caso que no ocurriría con la varianza.

4.5. Coeficiente de variación de Pearson.

- El **coeficiente de variación, CV**, es el cociente entre la desviación típica y la media.

Medida útil para comparar distribuciones distintas, este coeficiente no depende de las unidades en que se midan los valores de la variable y suele expresarse en tantos por ciento. Este coeficiente no es muy útil si la media aritmética está próxima a cero.

Nota:

Cuanto más pequeño sea este coeficiente de variación, los datos están más concentrados alrededor de la media y por tanto este será más representativo. Este coeficiente de variación permite comparar dos poblaciones heterogéneas.

Recuerda

El **coeficiente de variación** representa el número de veces que la desviación típica contiene a la media. Así, cuanto mayor sea su valor, mayor será la dispersión y menor la representatividad de la media. Se suele expresar como porcentaje.

Los anemómetros de dos estaciones meteorológicas han registrado la velocidad media diaria del viento, en km/h, durante cuatro jornadas.

Navacerrada: 0 5 8 15

Colmenar Viejo: 4 6 8 10

La media aritmética de los datos recogidos en cada estación es de 7 km/h, ¿crees que este valor proporciona suficiente información?

Para responder a la pregunta analizamos las **medidas de dispersión**.

x_i	f_i	$ x_i - \bar{x} f_i$	x_i^2	$x_i^2 \cdot f_i$
0	1	7	0	0
5	1	2	25	25
8	1	1	64	64
15	1	8	225	225
N	4	18		314

x_i	f_i	$ x_i - \bar{x} f_i$	x_i^2	$x_i^2 \cdot f_i$
4	1	3	16	16
6	1	1	36	36
8	1	1	64	64
10	1	3	100	100
N	4	8		216

- Rango:** $R_N = 15 - 0 = 15$ $R_C = 10 - 4 = 6$
- Desviación media:** $DM_N = \frac{18}{4} = 4,5$ $DM_C = \frac{8}{4} = 2$
- Varianza:** $\sigma_N^2 = \frac{314}{4} - 7^2 = 29,5$ $\sigma_C^2 = \frac{216}{4} - 7^2 = 5$
- Desviación típica:** $\sigma_N = \sqrt{29,5} = 5,43$ $\sigma_C = \sqrt{5} = 2,24$
- Coeficiente de variación:** $CV_N = \frac{5,43}{7} = 0,78$ $CV_C = \frac{2,24}{7} = 0,32$

5. VARIABLES ESTADÍSTICAS BIDIMENSIONALES. DIAGRAMAS DE DISPERSIÓN.

- Una **variable estadística bidimensional**, (X, Y) , de una población es aquella en la que se observan dos características, X e Y , y toma los valores: $(x_1, y_1), (x_2, y_2) \dots (x_n, y_n)$
- Un **diagrama de dispersión** o **nube de puntos** es una representación gráfica, de los valores que toma la variable bidimensional.


Ejemplo:

Un enfermero ha realizado un estudio para determinar la relación que puede existir entre la estatura, en cm, y la masa, en kg, de sus pacientes. Elige muestras de cada grupo de edad. La tabla recoge los datos obtenidos con sus pacientes de 16 años.

Estatura (X)	166	168	168	170	170	172	174	176	177	179
Masa (Y)	55	56	64	62	64	66	75	74	70	72

Observa que en este estudio se analizan dos características de la población. Decimos que las variables *estatura* y *masa* forman una **variable estadística bidimensional**.




Para conocer la relación entre ellas, representamos en un **diagrama de dispersión** los pares de puntos, (x, y) , que definen la variable bidimensional.



La relación entre las variables unidimensionales que forman la variable bidimensional se denomina **correlación**. Y dependiendo de la distribución de los puntos obtendremos diferentes **tipos de correlación**.

Ejercicio resuelto

- Observa estos diagramas de dispersión y determina qué tipo de relación existe entre las variables representadas.



Solución

a) Relación directa

b) Relación nula

c) Relación inversa